

Corpus arborés et parsing

Cours 2


Santiago Herrera
s.herrera@parisnanterre.fr

Lien


https://drive.google.com/drive/folders/1StwDH87QKnDppzVwkE7jrGJ2VbHNmB3f?usp=drive_link

Sondage : promo pluriTAL 2023

Auto-évaluation



Groupe 1



Groupe 2

Sondage : promo pluriTAL 2023

Langues parlées

A word cloud showing languages spoken by Group 1. The most prominent words are "français" (pink), "anglais" (blue), "chinois" (red), and "mandarin" (green). Other visible words include "espagnol" (orange), "russe" (yellow), "polonais" (orange), "japonais" (yellow), "coréen" (pink), "biélorusse" (pink), "cantonais" (blue), "marocain" (orange), "wolof" (orange), "occitan" (blue), "français" (blue), "espagnol - un poco" (green), and "deux dialectes chinois" (red).



Groupe 1

A word cloud showing languages spoken by Group 2. The most prominent words are "anglais" (blue), "français" (pink), and "chinois" (green). Other visible words include "espagnol" (red), "arabe" (purple), "allemand" (yellow), "kabyle" (blue), "ukrainien" (yellow), "russe" (orange), "choinois" (blue), "italien" (red), "turc" (red), "roumain" (blue), "coréen" (blue), "latin" (blue), "portugais" (blue), "tamoul" (blue), and "polonais" (blue).

Groupe 2

Sondage : promo pluriTAL 2023

Niveau du français





Groupe 1

Groupe 2

Sondage : promo pluriTAL 2023

Avez-vous fait de l'analyse syntaxique en dépendance ?



Groupe 1



Groupe 2

Rappel : treebank


Un treebank est une collection de phrases associées à des arbres syntaxiques

- Dans un treebank en dépendance


- Les connexions syntaxiques sont exprimées entre mots (unité d'analyse) vs. arbres de structure des phrases



Rappel : un arbre enraciné et étiqueté




Et des notions importantes :



Rappel : contraints dans l'analyse en dépendance


- 1) Un mot va être **racine** de la phrase
- 2) Chaque **mot dépendent exactement d'un seul mot**

Malgré ces contraints, nous avons des choix d'analyse



Rappel : treebanks aujourd'hui

- Format numérique, requêtable et encodé dans un conll-u
- Annotation simplifiée



```
# global.columns = ID FORM LEMMA UPOS XPOS FEATS HEAD DEPREL DEPS MISC
# sent_id = fr-ud-train_06412
# text = Je le conseille vivement.
1 Je moi PRON _ Emph=No|Number=Sing|Person=1|PronType=Prs 3 subj _ wordform=je
2 le lui PRON _ Emph=No|Gender=Masc|Number=Sing|Person=3|PronType=Prs 3 comp:obj
3 conseille conseiller VERB _ Mood=Ind|Number=Sing|Person=1|Tense=Pres|VerbForm=Fin 0 root _
4 vivement vivement ADV _ 3 mod _ SpaceAfter=No
5 . . PUNCT _ _ 3 punct _ _
```

Syntaxe

Définitions tirées du livre "Morphosyntax" (2022) de William Croft :

- **Syntax** is the analysis of the internal structure of utterances/**sentences** – more specifically, how **words** are put together.
- **Morphology** is the analysis of the internal structure of words, including prefixes, suffixes, and other internal changes to words that generally have a meaning.
- The term **morphosyntax** refers to the combination of morphology and syntax.

Mots

Il n'existe pas de définition canonique et universelle du mot :

- **Defining the word** (Haspelmath 2022): A word is (i) a free morph, or (ii) a clitic, or (iii) a root or compound plus possibly nonrequired affixes plus required affixes if there are any.


Universal dependencies :

- Basic units of annotation are syntactic words (not phonological or orthographic words)
 - dámelo [donnez-le moi] is 3 syntactic words: da me lo

Syntactic annotation at the word level can be problematic for agglutinative languages:

- Finnish: Republikaanitalousasiantuntijat [Experts économiques républicains] [link](#)
- Yupic: Mangteghaghllangllaghuytukut [Nous voulons construire une grande maison] [link](#)


Exemple en chinois




Unités d'analyse

- Première décision à prendre : segmenter en phrases
- Ensuite... Mots ? Morphèmes ? Tokens !


Couches d'annotation




Couches d'annotation




Couches d'annotation




Couches d'annotation



Couches d'annotation




Couches d'annotation



Annotation
morphosyntaxique /
Traits
morphologiques

Syntaxe de Grew-match



pattern { X -[subj]->Y }

pattern { X [form="attend"] }


pattern { X [upos=VERB] }

pattern { X [lemma="attendre"] }

pattern { X[Tense=Pres] }

Syntaxe de Grew-match : plusieurs contraints

```
pattern {
    V- [subj] ->S;
    V- [comp:obj] ->O;
    S[upos=PROPN, Number=Sing]
}
```



Syntaxe de Grew-match

pattern { V -[subj]-> S }

pattern { V [form="pensais"] }

pattern { V [lemma="penser"] }

pattern { V [upos=VERB, lemma="penser"]; V -[subj]-> S; V -[comp:obj]-> O }

pattern { V [upos=VERB] }

pattern { V [Tense=Past] }

pattern { V [lemma <> "manger"] }

Le lemme est différent à "see"

pattern { V [upos=VERB | AUX] }

Le POS est soit un VERB soit un AUX

À vous

Sur le treebank GSD en SUD du français (sauf indication)

- Cherchez tous les sujets (subj)
- Trouvez tous les lemmes (lemma) des auxiliaires (AUX)
- Cherchez toutes les phrases qui ont comme racine (root) un auxiliaire (AUX)
 - Réalisez la même requête en **UD**. Qu'est-ce qui se passe ?
 - Cherchez les phrases qui ont un auxiliaire **ou** un verbe comme racine
- Est-il possible d'avoir deux sujets (subj) sur le même verbe ?
- Est-il possible d'avoir deux objets (comp:obj) sur le même verbe ?

Encore Grew-match

N1 < N2

Le nœud N1 est immédiatement avant N2

N1 << N2

Le nœud N1 est avant N2

N1.feature = N2.feature

Égalité entre les valeurs des features

N1.feature <> N2.feature

Inégalité entre les valeurs des features

N1[upos=Verb, !Mood]

Négation d'une feature

without { N1[upos=NOUN] }

Application de contraintes plus générales


À vous

- Y a-t-il des nœuds qui n'ont pas d'upos ?
- Y a-t-il des pairs contigus DET-NOUN qui ne soit pas dans une relation déterminative (det)
- Trouvez
 - les paires DET-NOUN contigus qui ne s'accordent pas en genre.
 - les sujets qui se placent avant le verbe.
 - les phrases verbales sans sujet
- Comment est-il annoté le trigram “à partir de” ?
- Trouvez les verbes intransitifs
- Quels sont les adjectifs sans trait de genre ?

Surface Syntactic UD



- Alternative à l'UD
- Basés sur des critères distributionnels
- Les relations sont définies sur des bases distributionnelles et fonctionnelles.



CONLL-U

- Qu'est-ce qui se passe avec 'du', 'des', 'au', 'aux', etc.
- Colonne MISC?

```
# global.columns = ID FORM LEMMA UPOS XPOS FEATS HEAD DEPREL DEPS MISC
# sent_id = fr-ud-train_06412
# text = Je le conseille vivement.
1 Je moi PRON _ Emph=No|Number=Sing|Person=1|PronType=Prs 3 subj _ wordform=je
2 le lui PRON _ Emph=No|Gender=Masc|Number=Sing|Person=3|PronType=Prs 3 comp:obj
3 conseille conseiller VERB _ Mood=Ind|Number=Sing|Person=1|Tense=Pres|VerbForm=Fin 0 root _
4 vivement vivement ADV _ 3 mod _ SpaceAfter=No
5 . . PUNCT _ 3 punct _ _
```

```
# sent_id = fr-ud-train_04848
# text = Gouvernement du district
1 Gouvernement gouvernement NOUN _ Gender=Masc|Number=Sing 0 root _ wordform=gouvernement
2-3 du _ _ _ _ 
2 de de ADP _ _ 1 udep _ 
3 le le DET _ Definite=Def|Gender=Masc|Number=Sing|PronType=Art 4 det _ 
4 district district NOUN _ Gender=Masc|Number=Sing 2 comp:obj _
```